isec
Universidade Politécnica de Coimbra

# INTELIGÊNCIA COMPUTACIONAL

## PROJETO FASE II 26-27

## OTIMIZAÇÃO DO MODELO

## 1. Objetivo

O objetivo da Fase II do projeto consiste em aplicar técnicas de Inteligência de Enxame (***Swarm Intelligence***) à **otimização de redes neuronais**, com vista à melhoria do desempenho dos modelos de classificação desenvolvidos.

O trabalho deverá incidir sobre a **otimização do modelo implementado na Fase I do projeto** ou, em alternativa, sobre um novo modelo de classificação desenvolvido para esta fase.

O trabalho deverá incluir as seguintes componentes:

- **Implementação:** aplicação de algoritmos de Inteligência de Enxame à otimização do modelo de classificação.
- **Experimentação e avaliação:** comparação do desempenho do modelo de referência com os modelos obtidos através dos algoritmos de otimização.
- **Relatório técnico:** elaboração de um relatório com um máximo de 10 páginas, a uma coluna, em Times, tamanho 12 pt e espaçamento simples.
- **Apresentação e defesa:** apresentação oral e defesa do trabalho, com a duração máxima de 15 minutos.

O trabalho deverá ser desenvolvido em Python, recorrendo às bibliotecas e ferramentas utilizadas nas aulas, nomeadamente Scikit-learn, Keras, SwarmPackagePy Não devem ser utilizados modelos pré-treinados nesta fase.

## 2. Otimização de híper-parâmetros

O projeto deverá incluir a otimização automática de, pelo menos, **dois híper-parâmetros** do modelo de classificação, recorrendo a algoritmos de Inteligência de Enxame.

Os híper-parâmetros são valores definidos antes ou durante a configuração do processo de treino, que controlam a arquitetura do modelo ou o seu processo de aprendizagem. Ao contrário dos parâmetros aprendidos durante o treino, os híper-parâmetros têm de ser definidos ou selecionados através de um processo de configuração e otimização. No caso das redes neuronais, são exemplos de híper-parâmetros:

- Número de camadas e número de neurónios por camada;
- Funções de ativação;
- Taxa de aprendizagem (learning rate);

- Tamanho do lote (batch size);
- Coeficientes de regularização.

A seleção adequada destes híper-parâmetros pode influenciar significativamente o desempenho do modelo.

Entre os métodos tradicionais de otimização encontram-se a pesquisa em grelha (***Grid Search***) e a pesquisa aleatória (*Random Search*). A primeira pode exigir um elevado esforço computacional quando existem muitas combinações possíveis, enquanto a segunda explora combinações de forma aleatória, sem garantir que encontra uma boa solução dentro do orçamento de pesquisa disponível.

Neste projeto, pretende-se explorar a utilização de algoritmos de Inteligência de Enxame como métodos alternativos de otimização, avaliando a sua capacidade para identificar configurações de híper-parâmetros que melhorem o desempenho do modelo.

## 3. Algoritmos de Inteligência de Enxame

A otimização deverá utilizar o algoritmo **Particle Swarm Optimization (PSO)** como método de referência. Adicionalmente, deverá selecionar e implementar um outro algoritmo disponibilizado na biblioteca SwarmPackagePy, para comparar o seu desempenho com o PSO.

A comparação deverá ser realizada utilizando o mesmo modelo de classificação, os mesmos híper-parâmetros a otimizar e condições experimentais equivalentes, sempre que possível.

Independentemente da biblioteca ou algoritmo escolhido, deve-se implementar a função objetivo de acordo com o seguinte procedimento:

1. Recebe uma configuração de híper-parâmetros.
2. Constrói e treina a rede neuronal durante um número limitado de épocas.
3. Calcula uma métrica no conjunto de validação.
4. Devolve esse valor ao algoritmo de otimização.

## 4. Avaliação dos resultados

O trabalho deverá incluir uma análise comparativa dos resultados obtidos, contemplando, no mínimo:

- Desempenho do modelo de referência, antes da otimização;
- Desempenho do modelo otimizado com PSO;
- Desempenho do modelo otimizado com o segundo algoritmo selecionado;
- Comparação das métricas de classificação adequadas ao problema, como accuracy, precision, recall e F1-score;
- Análise do esforço computacional e do processo de otimização;
- Discussão crítica dos resultados, das limitações e das vantagens de cada abordagem.

A avaliação dos híper-parâmetros deverá utilizar dados de validação, **mantendo o conjunto de teste independente** do processo de otimização, de forma a permitir uma comparação justa do desempenho final dos modelos.

**Eficiência computacional da otimização:** Para reduzir o tempo de execução, recomenda-se limitar o número de indivíduos da população, o número de iterações e o número de épocas de treino durante a pesquisa de híper-parâmetros. Poderá também ser utilizado um subconjunto dos dados de treino na fase de otimização, desde que a configuração selecionada seja posteriormente avaliada com uma metodologia adequada e dados independentes de teste.
A comparação entre o PSO e o algoritmo selecionado deverá utilizar recursos computacionais equivalentes, nomeadamente em termos do número de avaliações da função objetivo. Deverão ser registados o tempo de execução, número de parâmetros e o desempenho dos modelos obtidos.

## 5. Âmbito e estrutura do relatório

O relatório deverá seguir a estrutura apresentada abaixo e responder às questões propostas. A análise deverá fundamentar as opções metodológicas adotadas e apresentar os resultados experimentais obtidos.

**i. Computação de Enxame (Swarm Intelligence) — até 2 páginas**

Em que consiste a Inteligência de Enxame e quais são os seus princípios fundamentais?
Descrever o paradigma de Inteligência de Enxame, os mecanismos de cooperação e pesquisa coletiva e as suas principais aplicações. Explicar de que forma estes algoritmos podem ser utilizados na otimização de redes neuronais.

**ii. Descrição e análise dos algoritmos — até 2 páginas**

Como funciona o algoritmo de Inteligência de Enxame selecionado e em que difere do PSO (***Particle Swarm Optimization***)?
Descrever o funcionamento do algoritmo selecionado, identificando os seus principais mecanismos, parâmetros e critérios de atualização das soluções. Comparar a sua abordagem com o PSO, discutindo as vantagens, limitações e diferenças relevantes para o problema de otimização em estudo.

**iii. Otimização de hiperparâmetros — até 4 páginas**

Como podem os algoritmos de Inteligência de Enxame melhorar o desempenho do modelo de classificação?
Aplicar o PSO e o algoritmo selecionado à otimização do modelo de classificação. Esta secção deverá incluir:

- Identificação de, pelo menos, dois híper-parâmetros a otimizar e definição dos respetivos intervalos ou conjuntos de valores possíveis.
- Descrição da função objetivo utilizada para avaliar as configurações candidatas.
- Apresentação da metodologia experimental, incluindo os dados utilizados, as condições de otimização e os critérios de avaliação.
- Identificação da melhor configuração de híper-parâmetros encontrada por cada algoritmo.
- Análise comparativa do desempenho dos algoritmos e do esforço computacional necessário.

A otimização deverá basear-se nos dados de treino e validação, reservando o conjunto de teste para a avaliação final dos modelos selecionados.

**iv. Conclusões e discussão dos resultados — 1 página**

Quais foram os principais resultados e que conclusões podem ser retiradas da experiência?

Sintetizar os resultados obtidos, discutindo o impacto da otimização no desempenho do modelo. Identificar as vantagens e limitações observadas, bem como possíveis melhorias e linhas de trabalho futuro.

## 6. Calendário

- **Entrega do relatório:** submissão no Moodle até **8 de novembro de 2026, às 20h00**.
- **Apresentação e defesa do projeto:** 9 e 13 de novembro de 2026, de acordo com o calendário a divulgar.

## 7. Regras e avaliação

**Submissão:** todas as entregas deverão ser efetuadas através do Moodle, num único ficheiro ZIP, contendo os elementos solicitados para o projeto.
**Grupos:** o projeto poderá ser realizado individualmente ou em grupos de dois estudantes.
**Apresentação e defesa:** a apresentação e a defesa do projeto são obrigatórias.
**Avaliação:** a classificação terá por base a apresentação e defesa do trabalho, considerando a compreensão dos conceitos, a implementação dos algoritmos, a metodologia experimental, a análise crítica dos resultados e a capacidade de justificar as opções tomadas.

A utilização de ferramentas de Inteligência Artificial Generativa deverá ser devidamente documentada **num relatório anexo**, que deverá incluir:

- **Prompt:** texto integral das instruções fornecidas à ferramenta.
- **Resposta gerada:** conteúdo produzido pela ferramenta em resposta ao prompt.
- **Análise crítica:** avaliação da correção e relevância da resposta obtida.
- **Contributo para o projeto:** identificação dos elementos utilizados, adaptados ou incorporados no trabalho.
- **Ligação:** disponibilização do link para a conversa ou interação com a ferramenta de IAG, que deverá permitir a consulta do conteúdo sem necessidade de autenticação ou início de sessão (login).

Recomenda-se organizar os prompts por tarefas, de forma a facilitar a identificação e a análise das diferentes utilizações da IAG.

**Cotação**
A Fase II do projeto tem uma **cotação de 3 valores**, na classificação final.